

КУРСОВОЙ ПРОЕКТ · ИССЛЕДОВАТЕЛЬСКАЯ ЧАСТЬ

AI-агент помощник для мониторинга приложений

Кейс от Cloud.ru · Исследование аудитории и потребностей

Команда №1: Меркулова Оксана · Белова Стефания · Егоров Никита · Зайцев Александр · Верменский Илья

Научный руководитель: Дмитрий Масленников

Что мы сделали за этот спринт

Целью исследования было выявить и подтвердить ключевые трудности dev-команд при мониторинге production и определить требования к AI-помощнику.

5

Исходных гипотез,
среди них H1 и H2 — RAT

4

Глубинных интервью
с DevOps / SRE

12

Источников desk research
для Buyer-сегмента

3

Сценария Cost of
Inefficiency
(база, конс., стресс)

22

Сгенерировано идей
решения

ВЕРДИКТ ПО ЭТАПУ

GO к прототипированию. Проблема предварительно подтверждена. RAT (H2) предварительно пройдена на сегменте primary users. H3 пивотим: фокус с «фильтрации шума» на «формирование контекста и гипотез причин». GO к разработке — только после buyer-валидации.

Проблема — словами заказчика

Что нам сказал Сергей Шапошников (Cloud.ru) на встрече 23 марта 2026 года — и почему это и есть продуктивное ядро.

СЕРГЕЙ ШАПОШНИКОВ · CLOUD.RU · 23.03.2026

«У нас бизнес связан с облаками, мы за счёт агентов улучшаем проникновение в наши сервисы. Решение принимают сотрудники, которые сами ответственны за мониторинг — лид определённого уровня команды, в зависимости от компании это может быть директор по эксплуатации, ведущий DevOps или SRE-шник.»

ЧТО ЭТО ОЗНАЧАЕТ ДЛЯ ПРОДУКТА

1. AI-агент = инструмент проникновения, не отдельный продукт

Cloud.ru хочет «улучшать проникновение в свои сервисы». Это диктует канал (маркетплейс Cloud.ru), модель (overlay поверх стека) и метрики (рост ARPU клиентов, не отдельная выручка).

2. Buyer ≠ User. Решение — у tech-руководителя

DevOps пользуется, но решение о покупке у Tech Lead / Head of Ops / CTO. Buyer-сегмент представлен через desk research (12 источников); первичная валидация — на следующем этапе.

DevOps теряет время не на починке — а на сборке картины происходящего

JOB-TO-BE-DONE

«Когда production-сервис ведёт себя странно, я хочу за 2–3 минуты понять что сломано и насколько критично, чтобы решить — реагировать сейчас или это можно отложить.»

ТРИ РАБОТЫ ОДНОВРЕМЕННО

Функциональная: быстро понять root cause и приоритет инцидента

Эмоциональная: уверенность, что не «пропустил» важный сигнал

Социальная: выглядеть компетентным перед командой и продуктом

ПЕРВИЧНЫЙ СЕГМЕНТ (USER)

DevOps / SRE-инженер дежурного контура

Контекст: сопровождает web-приложение в production, на ELK/Prometheus, с дежурствами 24/7

Триггер: алерт об отклонении или пользовательская жалоба, чаще всего — в неудобное время

Барьеры: фрагментация инструментов, отсутствие интерпретации, шум, переключение контекста

BUYER (предв. профиль через desk research): Tech Lead / Head of Ops / СТО. Оценивает через SLA, MTTR, стоимость дежурств и риски безопасности.

Двойная оценка масштаба

Рынок AIOps-overlay в РФ (TAM/SAM/SOM) + регулярная стоимость неэффективности у каждого клиента

РЫНОК ДЛЯ КЛИЕНТОВ CLOUD.RU

TAM 12–18 млрд ₽/год Рынок AIOps + observability tooling в РФ	SAM 1,5–3 млрд ₽/год AIOps-overlay для SMB / mid-market на Prometheus + ELK	SOM 100–250 млн ₽/год Реалистично для Cloud.ru за 12–18 мес
---	---	---

Top-down оценка по открытым источникам (IDC Russia, CNews); диапазоны требуют валидации с Cloud.ru — см. вопрос 2 на финальном слайде.

COST OF INEFFICIENCY НА ОДНОГО КЛИЕНТА — ГЛАВНАЯ ОПЕРАЦИОННАЯ ОЦЕНКА

Conservative ≈160 тыс ₽ / мес	Base ≈720 тыс ₽ / мес	Stress ≈2,3 млн ₽ / мес
--	--	--

Рынок плотный, но свободная ниша есть

АIOps-платформы (прямые)	Observability-стек (косвенные)	Incident-tooling (косвенные)	Статус-кво
ПРИМЕРЫ Datadog Watchdog, Dynatrace Davis, New Relic AI, BigPanda СИЛЬНО Автокорреляция событий, ML-аномалии, RCA-подсказки на исторических данных СЛАБО Замкнутые экосистемы, нужно «всё в одном вендоре». Дорого, нет адаптации к РФ-стеку	ПРИМЕРЫ Prometheus + Grafana, ELK, Zabbix СИЛЬНО Гибкость, бесплатность, открытые стандарты СЛАБО Нет интерпретации сигналов, всё на инженере вручную	ПРИМЕРЫ PagerDuty, Opsgenie, Better Stack СИЛЬНО Управление дежурствами, эскалация, ChatOps СЛАБО Не помогают разбираться в данных, только маршрутизируют	ПРИМЕРЫ Прыжки между Grafana, Kibana, Slack, runbook'ами СИЛЬНО Бесплатно, привычно СЛАБО Главный конкурент. По интервью на triage может уходить 30–60% времени инцидента

НАША НИША: AI-overlay поверх существующего стека ELK/Prometheus, который объясняет «что произошло и почему», без замены инфраструктуры. Дистрибуция через маркетплейс Cloud.ru как доп. сервис.

Beachhead — DevOps / SRE первой линии. Почему именно они

Из 4 потенциальных сегментов выбран один — primary user. Tech Lead и CTO — следующие контуры валидации как buyer / decision maker.

Сегмент	Концентрация боли	Цикл валидации	Размер	Вердикт
DevOps / SRE первой линии	Высокая (30–60 мин/инцидент)	Короткая (1 спринт)	Большой	Beachhead MVP
Tech Lead / Head of Ops	Средняя (через MTTR)	Средняя	Средний	Buyer-валидация
CTO / Архитектор enterprise	Низкая (стратег. метрики)	Длинная (3–6 мес)	Малый, дорогой	Поздний enterprise
Координатор инцидентов	Очень высокая, узкий контекст	Средняя	Очень малый	Вне scope MVP

4 ПРИЧИНЫ ВЫБОРА BEACHHEAD «DEVOPS / SRE ПЕРВОЙ ЛИНИИ»

a

Концентрация боли

Прямая операционная ценность от assistant-слоя; 30–60 мин/инцидент по интервью.

b

Короткий цикл валидации

Команды автономны в выборе tooling. Concierge MVP за 1 спринт, не 3–6 мес.

c

Критическое мышление

Глубоко погружены в стек — критически оценят AI, не дадут ложно-положительной оценки.

d

Стратегический fit

Основные пользователи observability-сервисов Cloud.ru. Retention-эффект напрямую.

5 гипотез, 1 RAT, 4 интервью + desk research для Buyer'a

ГИПОТЕЗЫ И ИХ СТАТУС ПОСЛЕ ИНТЕРВЬЮ

H1 DevOps теряет много времени на triage и сбор контекста при инцидентах	Предв. подтверждена
H2 · RAT Даже при наличии Prometheus / ELK командам не хватает слоя интерпретации: что произошло, почему и что проверить первым	RAT предв. пройден
H3 Главная боль — шум алертов / alert fatigue	Не подтверждена → Pivot
H4 Команды готовы к проактивному режиму (предупреждения до инцидента)	Не валидирована, R2
H5 AI-сводка будет полезна только при explainability: ссылках на метрики, логи и deploy-события	Предв. подтв. с условием

ВЫБОРКА

ИНТЕРВЬЮ (USER) 4 Глубинные интервью DevOps и SRE из IT-команд, опыт 3+ года, производство web-сервисов на ELK/Prometheus. Методичка для B2B: допустимо <10 при условии охвата ключевых ролей. Buyer-сегмент представлен через desk research.	
RAT — RISKIEST ASSUMPTION TEST H2: «Даже при наличии Prometheus / ELK командам не хватает слоя интерпретации: что произошло, почему и что проверить первым.»	

5 инсайтов, которые меняют картину продукта

1

Алерты НЕ шум — а сигнал «иди смотри»

Респонденты не жалуются на «слишком много алертов». Они жалуются на то, что после алерта непонятно, что именно сломалось.

«Алерт обычно сразу указывает на проблему, шум — это не основная боль.»

2

Главная потеря — на triage и сборке контекста

По интервью на переключение между Grafana, Kibana, Slack и runbook'ами может уходить 30–60% времени инцидента. Сам fix занимает меньше.

«Я трачу полчаса не на починку, а на то, чтобы собрать картину.»

3

Доверие к AI = объяснимость + ссылки на сырые данные

Никто не примет «голый» вывод AI. Все хотят видеть, на каких метриках/логах сделан вывод и иметь возможность кликнуть в источник.

«Если я не вижу, откуда взялся вывод, — я ему не верю и проверю всё сам.»

4

Поздний detection — ошибка восприятия серьезнее, чем шум

Боятся не «лишнего алерта», а «сигнала, который ушёл в спам и потом стрельнул как outage». Это и есть рычаг ценности.

«Самый страшный сценарий — узнать о проблеме от клиента раньше, чем от мониторинга.»

5

Корреляция с deploy-событиями — топ-1 запрос


Желание №1: «покажите, какие изменения коммитились перед инцидентом». По интервью это один из первых вопросов инженера при triage: «что вкатывали за последние часы?»

«Первое, что я спрашиваю на инциденте — что вкатили за последние 2 часа?»

Эмоциональная яма — на этапе triage. Туда и должен бить продукт

Карта пути дежурного DevOps от срабатывания алерта до закрытия инцидента (As-Is, без AI-ассистента).

Этап 1: Алерт	Этап 2: Проверка	Этап 3: Triage	Этап 4: Действие	Этап 5: Постмортем
Алерт прилетает в Slack. Дежурный отрывается от задачи. «Опять что-то...»	Открыть Grafana, Kibana. Понять — реально упало или ложняк. «Это вообще критично?»	Прыжки между 3–4 инструментами. Сбор контекста. Главная боль. «Где смотреть? Что вкатили?»	Откат, перезагрузка, эскалация. Часто понятно что делать. «ОК, делаем rollback.»	Запись в журнал, обсуждение в чате. Часто откладывается. «Потом разберёмся.»



От данных — к решению. Что мы изменили в продукте

Каждое продуктовое решение опирается на конкретное наблюдение из интервью или анализа. Это не сторителлинг — это трассируемый Pivot/Persevere.

ДАННЫЕ / EVIDENCE	ЧТО ПОНЯЛИ	ЧТО ИЗМЕНИЛИ В ПРОДУКТЕ	ВЕРДИКТ
4/4 респондента описали ручной сбор контекста между Grafana, Kibana, Slack	Главная боль — не сбор данных, а сборка картины происходящего	Core: auto-summary в момент алерта	PERSEVERE
3/4 респондента: «алерт обычно сразу указывает на проблему»; НЗ о шуме не подтвердилась	Шум алертов — не главный болевой контур (по крайней мере, у опытных команд)	Убрали из MVP snooze-логику, фильтрацию шума, alert grouping	PIVOT
4/4 респондента: «без ссылок на источник AI не доверюсь — проверю всё сам»	Доверие = объяснимость. Trust-layer обязателен.	Добавили T1 «Объясни почему» как сквозное требование MVP	PERSEVERE
Только 2/4 респондента описали кейсы с сигналами-предвестниками деградации	Готовность к proactive не валидирована на этой выборке	Proactive — равноправный трек, отложен в Release 2 до валидации H4	ОТЛОЖЕНО
Buyer (Tech Lead/CTO) не покрыт первичными интервью — только desk research	Покупательская готовность не валидирована	Отдельный поток buyer-валидации в плане следующего этапа	ПРОБЕЛ

Каждое продуктовое решение опирается на данные. Где данных нет — фиксируем как пробел и закрываем на следующем этапе валидации.

Buyer пока не интервьюирован — предварительный профиль собран через desk research

Honest disclosure: в выборке нет Tech Lead / CTO / Head of Ops. Закрыли desk research-ом по методике B2B-discovery.

ПРОФИЛЬ ЛИЦА, ПРИНИМАЮЩЕГО РЕШЕНИЕ

Tech Lead / Head of Ops / CTO

По чему оценивает: SLA, MTTR, стоимость дежурств, безопасность, риск vendor lock-in

Чего боится: новый «чёрный ящик» в production, утечка данных, дополнительные SLA-риски

Что любит: пилоты с измеримым эффектом за 1–2 спринта, понятную ценовую модель, on-prem или отечественное облако (Cloud.ru ✓)

ИСТОЧНИКИ DESK RESEARCH

1. Splunk State of Observability 2024
2. DORA / Google State of DevOps 2024
3. Gartner Market Guide for AIOps 2024
4. Forrester TEI на observability-инструменты
5. PagerDuty Incident Response Report
6. IDC Russia: рынок enterprise IT-monitoring
7. Habr: 6 публичных постмортемов RU IT-компаний
8. vc.ru: интервью с CTO / Head of Ops
9. Cloud.ru: case studies клиентов 2024–25
10. SRE Weekly + transcripts SREcon EMEA
11. Datadog / New Relic public case studies
12. Цитата С. Шапшикова (Cloud.ru, 23.03.26)

Точка зрения и направление поиска решения

POINT OF VIEW • ОСНОВНАЯ ТОЧКА ЗРЕНИЯ

DevOps / SRE-инженер на дежурстве, получивший production-алерт во вне-рабочее время, **нуждается в готовой контекстной сводке инцидента** с явной гипотезой причины, потому что под стрессом и в ограниченном времени собирать картину из 3–4 источников долго и легко ошибиться, **но сейчас этому мешает фрагментация инструментов и отсутствие автоматического слоя интерпретации.**

HOW MIGHT WE — НАПРАВЛЕНИЯ ДЛЯ ГЕНЕРАЦИИ РЕШЕНИЙ

HMW 1

Как сократить время сборки контекста инцидента с 30 минут до 2 минут?

HMW 2

Как дать DevOps готовую гипотезу root cause со ссылками на сырые данные, не теряя его доверия?

HMW 3

Как связать алерт с deploy-событиями и недавними изменениями за 1 клик?

Из 22 идей — 3 value-фичи + 1 trust-слой в ядро MVP

Это вход в следующий спринт. Value-фичи создают ценность; trust-layer — обязательное условие принятия.

CORE VALUE FEATURES — СОЗДАЮТ ЦЕННОСТЬ ДЛЯ ПОЛЬЗОВАТЕЛЯ

V1 · ICE 576	V2 · ICE 480	V3 · ICE 448
Auto-summary инцидента Сводка «что случилось, что затронуто, что подозреваем» в момент срабатывания алерта в Slack/Telegram	AI-гипотеза root cause Один абзац: «Скорее всего причина в X, потому что Y, Z». Текст без ссылок не публикуется.	Корреляция с deploy-событиями Автосопоставление алерта с коммитами/релизами/изменениями конфигов за последние N часов

TRUST LAYER — ОБЯЗАТЕЛЬНОЕ УСЛОВИЕ ПРИНЯТИЯ AI-ВЫВОДОВ (НЕ САМОСТОЯТЕЛЬНАЯ ЦЕННОСТЬ)

T1 ICE 720	«Объясни почему» / Explainability Под каждым AI-выводом — кнопка, раскрывающая chain of reasoning со ссылками на метрики, логи и события. Без T1 V1, V2, V3 не будут приняты пользователями: 4/4 респондентов прямо назвали условием доверия — возможность проверить вывод. Поэтому T1 — не отдельная фича, а сквозное требование к UX и архитектуре всего MVP.
---------------	--

Зачем это Cloud.ru

Продукт работает поверх Prometheus/ELK клиента → Cloud.ru = канал дистрибуции и платформа исполнения.



Новый источник выручки

AI-overlay может продаваться клиентам Cloud.ru как paid add-on.
Модель монетизации — revenue-share или комиссия.

Гипотеза: рост ARPU



Углубление привязки

Использование AI-ассистента может стимулировать потребление базовых сервисов: compute, storage, Managed Kubernetes.

Гипотеза: ↑ потребление



Дифференциация против AWS/GCP

Локальный AI-сервис на отечественной телеметрии.
Compliance, on-prem, RU-облако — то, что зарубежные вендоры не предлагают.

Сильный рыночный
аргумент



Снижение оттока

Команды с встроенным AI-ассистентом труднее мигрируют на конкурентов. Привязка через дополнительный value-layer.

Гипотеза: ↓ churn

Цитата заказчика (С. Шапошников, Cloud.ru, 23.03.2026): «У нас бизнес связан с облаками, мы за счёт агентов улучшаем проникновение в наши сервисы».

GO к прототипированию + 4 потока валидации

GO

GO к прототипированию — не GO к полноценной разработке. Решение GO к Delivery — только после buyer-интервью и измеримого эффекта пилота.

ЧЕТЫРЕ ПОТОКА ВАЛИДАЦИИ ПОСЛЕ ЗАЩИТЫ ИССЛЕДОВАТЕЛЬСКОЙ ЧАСТИ

1	Глубинные интервью (расширение) 8–10 интервью × 30–45 мин <i>Рекрут стартует следующим спринтом</i>	Критерий: ≥6 из 8 подтверждают triage / context assembly как значимую регулярную боль	Недели 1–3
2	Buyer-интервью Минимум 2, цель 4 интервью × 45 мин <i>Закрывает методологический пробел</i>	Критерий: ≥3 из 4 готовы рассмотреть платный пилот	Недели 1–4
3	Юзабилити-тесты прототипа 5 сессий × 30–45 мин <i>Готов после потоков 1 и 2</i>	Критерий: ≥4 из 5 завершают сценарий за ≤5 мин без модератора	Недели 3–4
4	Concierge MVP / pilot 1–2 пилотные команды × 4 недели <i>Требуем ресурс от Cloud.ru</i>	Критерий: Time-to-Hypothesis -30%; ≥70% оценок «полезно»; ≥50% AI-гипотез помогли сузить поиск	Недели 5–8

К защите в июне: 8–10 интервью + 4 buyer-интервью + 5 UX-сессий + 1–2 пилота. Полный план с ресурсами и метриками — раздел 15 документа.

Что запрашиваем у вас сегодня

Три ресурса от Cloud.ru + четыре открытых вопроса. Далее команда самостоятельно ведёт discovery / prototype-этап при поддержке Cloud.ru по контактам и данным.

РЕСУРСЫ

А

Контакты 2–3 SMB / mid-market клиентов

С активными dev-командами на Prometheus / ELK. Для потока 1 (CustDev) и потока 4 (conciierge MVP).

В

Доступ к менеджеру pre-sales / customer success

30–45 мин разговора для потока 2 (Buyer-интервью). Реконструируем контур принятия решения.

С

Доступ к историческим данным инцидентов

Полностью анонимизированные данные одного-двух пилотных клиентов (без PII, без названий компаний и сервисов). Уточнит ранжирование сценариев (раздел 13.6).

4 ВОПРОСА К ЗАКАЗЧИКУ

1

Согласны ли с фокусом MVP на сценарии «регрессия после релиза» + «деградация под нагрузкой»?

2

Какой ARPU добавки реалистичен на типового клиента Cloud.ru за AI-overlay?

3

Готовы ли поддержать 1–2 пилотных аккаунта на следующем этапе?

4

Какие compliance-ограничения критичны при доступе к логам клиентов (PII, on-prem)?

Команда №1: Меркулова Оксана · Белова Стефания · Егоров Никита · Зайцев Александр · Верменский Илья · Научный руководитель: Дмитрий Масленников

Спасибо! Открыты к диалогу.